

Desafío - Fundamentos del método científico y probabilidad

En este desafío validaremos nuestros conocimientos de Distribuciones de probabilidad muestreo. Para lograrlo, necesitarás aplicar lo aprendido hasta el momento.

Lee todo el documento antes de comenzar el desarrollo **individual**, para asegurarte de tener el máximo de puntaje y enfocar bien los esfuerzos.

// Tiempo asociado: 2 horas cronológicas.

Descripción

Eres un analista de datos en una empresa de logística nacional. La empresa ha registrado los tiempos de miles de entregas y quiere entender la variabilidad en los tiempos promedio de entrega para poder ofrecer mejores estimaciones a los clientes.

Tu tarea es demostrar el Teorema del Límite Central (TLC) y utilizar la distribución muestral de la media para calcular la probabilidad de observar ciertos resultados en una muestra de entregas.

Resultado de Aprendizaje a Evaluar:

- Realizar cálculos de probabilidad utilizando la distribución muestral para resolver un problema.

Instrucciones

Utiliza el siguiente código para generar la población de datos. Este DataFrame simula los tiempos de entrega (en minutos) de todas las entregas realizadas por la empresa.

```
Python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

# Generar datos consistentes para todos
np.random.seed(10)
```

```
# Generamos una población con una distribución Gamma (no normal)
# Parámetros de la distribución Gamma
shape, scale = 2.5, 30
poblacion_tiempos = np.random.gamma(shape, scale, 5000)

# Calculamos la media y desviación estándar REAL de la población
media_poblacional = np.mean(poblacion_tiempos)
std_poblacional = np.std(poblacion_tiempos)

print(f"La media poblacional ( $\mu$ ) es: {media_poblacional:.2f} minutos")
print(f"La desviación estándar poblacional ( $\sigma$ ) es: {std_poblacional:.2f} minutos")

# Visualizamos la distribución de la población (que no es normal)
sns.histplot(poblacion_tiempos, kde=True)
plt.title("Distribución de Tiempos de Entrega (Población Total)")
plt.xlabel("Tiempo de Entrega (minutos)")
plt.ylabel("Frecuencia")
plt.show()
```

Requerimientos

1. Simulación de la Distribución Muestral:

- Toma 1000 muestras aleatorias de la población. Cada muestra debe tener un tamaño de $n=40$.
- Para cada una de las 1000 muestras, calcula su media.
- Guarda todas las medias de las muestras en una lista o arreglo de NumPy llamado `medias_muestrales`.

2. Análisis del Teorema del Límite Central (TLC):

- Calcula la media y la desviación estándar de tu lista `medias_muestrales`.
- **Compara tus resultados:**
 - ¿La media de las medias muestrales es similar a la `media_poblacional`?
 - Calcula el error estándar teórico usando la fórmula del TLC: $SE = \frac{\sigma}{\sqrt{n}}$. ¿Este valor es similar a la desviación estándar que obtuviste de tus `medias_muestrales`?
- Genera un histograma de las `medias_muestrales`. ¿Qué forma tiene esta distribución?
- *Escribe tus respuestas a las preguntas de comparación como comentarios en el código.*

3. Cálculo de Probabilidades:

- Asumiendo que la distribución de las medias muestrales es normal (gracias al TLC), **calcula la probabilidad de que una muestra aleatoria de 40 entregas tenga una media de 72 minutos o menos.**
- Deberás estandarizar el valor (calcular el Z-score) y utilizar la distribución normal estándar para encontrar esta probabilidad.



¡Mucho éxito!

Estudiante: Valeria Fariña

Programa: Especialización en Fundamentos de Ciencia de Datos

Institución: IGT Chile / Corporación Nueva Ciaspo (SENCE - Talento Digital para Chile)

URL del Repositorio:

https://github.com/ValeriaPFR/Desafio12_DistribucionesProbabilidadesMuestreo_RTD-25-01-13-0058-4.git

Desarrollo

4. Introducción y Objetivo

En el negocio de la logística, dar un tiempo estimado de entrega preciso es clave para la satisfacción del cliente. Sin embargo, en el día a día ocurren imprevistos: tráfico pesado, problemas de clima o demoras en la carga de paquetes. Esto hace que analizar entregas individuales sea complicado y poco confiable para hacer promesas de servicio.

Para solucionar este problema, en este estudio analizamos el comportamiento de los tiempos de entrega no de forma individual, sino agrupando las entregas en lotes. Utilizando un principio fundamental de la estadística (el Teorema del Límite Central-TLC), demostramos cómo la agrupación de datos nos permite predecir los tiempos de entrega con alta precisión y calcular la probabilidad de cumplir metas de tiempo operativas.

5. Metodología

Para este análisis se registraron los tiempos de 5.000 entregas realizadas por la empresa:

- *Tiempo promedio por paquete:* 74,52 minutos. Es lo que tarda en promedio un envío individual.
- *Variación de los tiempos:* 47,11 minutos. Muestra que las entregas individuales cambian muchísimo entre sí (hay envíos muy rápidos y otros muy lentos).

Debido a esta alta variación en envíos individuales, medir el desempeño paquete por paquete no es eficiente. Por eso, el análisis se realiza evaluando el tiempo promedio de lotes de entregas.

Simulé el trabajo diario de la empresa tomando 1.000 grupos o lotes de entregas al azar. Cada grupo contenía 40 entregas ($n=40$). A cada uno de esos 1.000 grupos le calculé su tiempo promedio. El objetivo era observar cómo se comportaban esos promedios al compararlos con los datos generales de la empresa.

6. Resultados

Al juntar y graficar los promedios de los 1.000 grupos, se encuentran tres conclusiones clave:

1. *El promedio de los grupos es exacto:* El tiempo promedio de todos los grupos juntos fue de 74,45 minutos, prácticamente idéntico al promedio real de la empresa (74,52 minutos). Esto confirma que trabajar con promedios por lote refleja perfectamente la realidad de la operación.

2. *Los promedios varían mucho menos:* Mientras que los envíos individuales varían casi 47 minutos, la diferencia entre el promedio de un grupo y otro fue de solo 7,42 minutos. Agrupar entregas reduce la incertidumbre.
3. *Se forma una curva perfecta ("Campana"):* Aunque los tiempos individuales son caóticos y desiguales, los promedios de grupos de 40 siempre forman una curva suave y equilibrada (llamada Distribución Normal). La mayoría de los grupos se concentran cerca de los 74 minutos y muy pocos se alejan a los extremos.
4. Gracias a que los promedios por grupo se comportan de forma ordenada y predecible, pudimos calcular qué tan probable es que un lote de 40 entregas se complete en un promedio de **72 minutos o menos**.
 - *Resultado:* Existe un 37,07% de probabilidad de que un lote aleatorio de 40 entregas cumpla con esa meta de tiempo.
 - *En palabras sencillas:* Aproximadamente casi 4 de cada 10 lotes de trabajo lograrán un promedio de 72 minutos o menos. El resto (63%) tomará un poco más de tiempo.

7. Ejecución del script de Python

Los resultados generados por la consola (Figura 1) confirman la coherencia entre el comportamiento de los datos simulados y las predicciones teóricas. La población total de entregas registra un tiempo promedio (μ) de 74,74 minutos con una dispersión (σ) de 47,26 minutos. Al evaluar el comportamiento muestral, el promedio de las 1.000 muestras simuladas ($\mu_{\bar{x}}$) se ubicó en 74,43 minutos, alcanzando una aproximación casi exacta al valor real de la población. Asimismo, la dispersión medida entre los promedios de los grupos fue de 7,62 minutos, manteniendo una estrecha alineación con el valor teórico calculado de 7,47 minutos ($\sigma/\sqrt{n}$). Finalmente, la meta de 72 minutos se sitúa ligeramente por debajo de la media con un valor Z de $-0,3672$, lo que arroja una probabilidad acumulada final del 35,67% de que un lote de 40 entregas complete su recorrido en ese tiempo o menos. El detalle del script de Python se encuentra en el hipervínculo del inicio del informe.

```
--- DATOS DE LA POBLACIÓN REAL ---  
Media poblacional ( $\mu$ ): 74.74 minutos  
Desviación estándar poblacional ( $\sigma$ ): 47.26 minutos  
  
--- ANÁLISIS DEL TEOREMA DEL LÍMITE CENTRAL ---  
Media de todas nuestras muestras: 74.43 minutos  
Desviación estándar empírica de las muestras: 7.62 minutos  
Error estándar teórico calculado: 7.47 minutos  
  
--- RESULTADO DEL CÁLCULO DE PROBABILIDAD ---  
Z-score (distancia en desviaciones estándar): -0.3672  
Probabilidad de que el promedio sea de 72 minutos o menos: 35.67%
```

Figura 1. Salida de consola con los resultados del script de Python.


La gráfica de la figura 2, presenta la **distribución de frecuencias de las medias muestrales** obtenidas mediante la simulación de tiempos de entrega, junto con su curva de estimación de densidad de kernel (KDE).

- **Representación de datos:**

- **Eje X (Tiempo Promedio de Entrega):** Variable continua ajustada en un rango aproximado de 55 a 105 minutos.
- **Eje Y (Cantidad de Muestras):** Frecuencia absoluta de promedios muestrales agrupados por intervalos.
- **Histograma y Curva de Densidad:** Las barras turquesa y la curva continua reflejan la convergencia hacia una **Distribución Normal (Campana de Gauss)**, lo que valida empíricamente el **Teorema del Límite Central (TLC)** a partir de muestras de tamaño $n=40$.

- **Análisis de Parámetros de Tendencia Central:**

- **Media Poblacional Real** ($\mu = 74,74$ min): Indicada con la línea discontinua roja.
- **Media Muestral** ($\bar{X}_x = 74,43$ min): Indicada con la línea punteada azul.
- **Conclusión visual:** La superposición casi exacta de ambas líneas de referencia demuestra la **insesgadidez del estimador**, confirmando que el promedio de las medias muestrales es una estimación precisa del parámetro poblacional.



8. Conclusión

- **Promesas de servicio más reales:** Ahora la empresa sabe con respaldo numérico que prometer un promedio de 72 minutos por lote se cumplirá en cerca del 37% de los casos. Para promesas de servicio con mayor margen de garantía, conviene ajustar las metas más cerca de los 74 - 75 minutos.
- **Control de calidad en rutas:** Si un lote de 40 entregas llega a promediar más de 89 minutos, la empresa sabrá de inmediato que no fue "mala suerte", sino un problema operativo real en la ruta o el camión que requiere atención inmediata.